

Valorisations boursières du S&P 500

Dépôt de jeu de données — description et premier résumé statistique (R)

503

entreprises

350

individus complets

153

individus incomplets

8 + 4

variables quanti. + quali.

1. Source

Jeu de données public « **S&P 500 Companies with Financial Information** », publié sur **datahub.io** (`core/s-and-p-500-companies-financials`) et sur GitHub (`datasets/s-and-p-500-companies-financials`). Les données financières proviennent de **Yahoo Finance**. Une ligne correspond à une entreprise de l'indice. Chargement direct dans R avec `read.csv(url)`. Capitalisation et EBITDA sont exprimés en dollars bruts.

2. Problématique

Les valorisations boursières (P/E, P/B) dépendent-elles du secteur, de la taille de l'entreprise et de sa politique de dividende ? Le fichier ne contient pas de rendements boursiers : l'étude porte donc sur les niveaux de valorisation, et non sur le couple rendement/risque.

3. Individus complets et incomplets

`sum(complete.cases(sp))` donne **350 individus complets** sur 503, soit **153 individus incomplets** (30%). Les données manquantes ont trois origines :

Origine	Effet
17 entreprises sans aucune donnée Yahoo (ex. Ansys, Hess, Marathon Oil, Discover : sorties de l'indice ou rachetées)	Toutes les variables numériques manquantes
87 entreprises qui ne versent pas de dividende (Amazon, Adobe, Boeing...)	Dividend Yield = NA (le fichier ne contient aucun 0)
Bénéfices ou fonds propres négatifs, données non publiées	Price/Earnings (45 NA), EBITDA (44), Price/Book (20)

4. Description des variables

Variables quantitatives (continues, issues du fichier). Dans R, `read.csv()` remplace « / » et les espaces par des points.

Variable	Nom dans R	Signification
Price	Price	Cours de l'action (\$)
Price/Earnings	Price.Earnings	Ratio cours / bénéfice (P/E) — variable expliquée
Price/Book	Price.Book	Ratio cours / valeur comptable (P/B) — variable expliquée
Earnings/Share	Earnings.Share	Bénéfice par action (\$), peut être négatif
Dividend Yield	Dividend.Yield	Rendement du dividende (0,02 = 2 %)
Market Cap	Market.Cap	Capitalisation boursière (\$ bruts)
EBITDA	EBITDA	Excédent brut d'exploitation (\$ bruts), peut être négatif
Price/Sales	Price.Sales	Ratio cours / chiffre d'affaires

Variables d'identification, non analysées : `Symbol`, `Name`, `SEC Filings` (lien), `52 Week Low / 52 Week High` (servent à construire la proximité du plus haut).

Variables qualitatives construites

Variable	Type	Construction	Modalités (effectifs)
Secteur	Nominale, 11 mod.	La colonne <code>Sector</code> contient en fait la sous-industrie GICS (127 valeurs) ; regroupement dans les 11 secteurs GICS	Industrials 78, Financials 72, Information Technology 69, Health Care 62, Consumer Discretionary 50, Consumer Staples 38, Real Estate 31, Utilities 31, Materials 28, Communication Services 22, Energy 22
Dividende	Binaire	oui si <code>Dividend Yield > 0</code> ; non si rendement absent	oui 399 · non 87 · NA 17

Variable	Type	Construction	Modalités (effectifs)
Taille	Ordinale, 3 mod.	Terciles de Market Cap avec cut() et quantile() ; seuils $\approx 23,7$ et 71,0 Md\$	petite 162 · moyenne 162 · grande 162 · NA 17
Proche du plus haut	Binaire	oui si Price > 0,9 × 52 Week High	oui 100 · non 386 · NA 17

Ces variables couvrent les 8 situations de test de liaison : quanti/quanti, quali/quali, quanti/quali à 2 groupes et à 3 groupes ou plus.

5. Sortie de summary(sp)

Symbol	Name	Sector	Price	Price.Earnings
Length:503	Length:503	Length:503	Min. : 0.522	Min. : 0.032
Class :character	Class :character	Class :character	1st Qu.: 67.530	1st Qu.: 15.831
Mode :character	Mode :character	Mode :character	Median : 132.185	Median : 22.307
			Mean : 218.997	Mean : 55.214
			3rd Qu.: 263.085	3rd Qu.: 32.489
			Max. :5993.850	Max. :9001.334
			NA's :17	NA's :45
Dividend.Yield	Earnings.Share	X52.Week.Low	X52.Week.High	Market.Cap
Min. :0.00004	Min. : -21.490	Min. : 0.513	Min. : 17.65	Min. :2.355e+06
1st Qu.:0.01055	1st Qu.: 2.550	1st Qu.: 54.820	1st Qu.: 88.65	1st Qu.:1.862e+10
Median :0.01990	Median : 5.680	Median : 103.110	Median : 169.30	Median :3.851e+10
Mean :0.02331	Mean : 9.262	Mean : 165.603	Mean : 275.63	Mean :1.466e+11
3rd Qu.:0.03315	3rd Qu.: 10.900	3rd Qu.: 187.968	3rd Qu.: 315.71	3rd Qu.:9.234e+10
Max. :0.08120	Max. :384.810	Max. :5501.010	Max. :8200.00	Max. :5.649e+12
NA's :104	NA's :17	NA's :17	NA's :17	NA's :17
EBITDA	Price.Sales	Price.Book	SEC.Filings	
Min. : -2.900e+09	Min. : 0.1726	Min. : -314.902	Length:503	
1st Qu.: 1.796e+09	1st Qu.: 1.5334	1st Qu.: 1.671	Class :character	
Median : 3.456e+09	Median : 2.9425	Median : 2.861	Mode :character	
Mean : 8.857e+09	Mean : 4.4191	Mean : 13.592		
3rd Qu.: 7.081e+09	3rd Qu.: 5.6344	3rd Qu.: 6.830		
Max. : 2.013e+11	Max. :73.6812	Max. :2322.172		
NA's :44	NA's :18	NA's :20		

À noter : P/E très asymétrique (médiane 22, moyenne 55, max 9 001) et P/B parfois négatif (fonds propres négatifs). Des tests non paramétriques ou une transformation logarithmique seront à envisager.